Retificação da Extração e Banco de Dados: Provas da OAB

Registro da extração executada | Projeto do time de dados para o time de LLM

Escopo da extração realizada

O acervo extraído cobre os exames 2010.2, 2010.3 e IV a XLVII: 46 edições disponíveis na fonte oficial. A coleta inclui a prova objetiva da 1ª fase, caderno tipo 1, gabaritos preliminares e definitivos quando publicados e comunicados oficiais de anulação ou retificação. Não inclui tipos 2, 3 e 4 nem documentos da 2ª fase.

O parser identificou 100 questões nos exames 2010.2 e 2010.3 e 80 nos demais exames do acervo. O questionário de percepção anexado ao caderno 2010.2 não entra como questão. Nos gabaritos XII a XIV, foi lida a tabela de correspondência dos tipos para extrair as respostas do tipo 1.

Matérias

As faixas abaixo foram aplicadas pelo código às provas de 80 questões a partir do XVI Exame. Antes do XVI, `materia` permanece vazia porque a distribuição histórica ainda não foi validada.

Matéria	Questões	Matéria	Questões
Ética Profissional	1 a 8	Filosofia do Direito	9 e 10
Direito Constitucional	11 a 16	Direitos Humanos	17 e 18
Direito Eleitoral	19 e 20	Direito Internacional	21 e 22
Direito Financeiro	23 e 24	Direito Tributário	25 a 29
Direito Administrativo	30 a 34	Direito Ambiental	35 e 36
Direito Civil	37 a 42	ECA	43 e 44
Direito do Consumidor	45 e 46	Direito Empresarial	47 a 50
Processo Civil	51 a 56	Direito Penal	57 a 62
Processo Penal	63 a 68	Direito Previdenciário	69 e 70
Direito do Trabalho	71 a 75	Processo do Trabalho	76 a 80

Fonte dos dados e organização

Fonte: página oficial de Editais e Provas da OAB/FGV. O acervo cobre 2010.2 a 2026, até o XLVII Exame, com 46 edições e 3.720 linhas de questões estruturadas.

As pastas seguem `numero_exame_ano_Ttrimestre`, com ano e trimestre civil da aplicação (exemplo: `16_2015_T1`). Os identificadores 2010.2 e 2010.3 são mantidos. Cada PDF começa com o nome da pasta, seguido do tipo de documento, data e título oficial.

Como o texto foi extraído

O texto foi extraído com Python e `uv`. O PyMuPDF (`pymupdf`) leu o texto e as páginas dos PDFs. Quando a codificação estava corrompida, o código acionou o RapidOCR local. O parser separou enunciado e alternativas A a D, leu os gabaritos e associou fontes por caminhos relativos ao projeto.

Estrutura entregue

A saída principal é o banco SQLite. Também foram gerados um arquivo `.sql` compatível com SQLite e um CSV UTF-8 com BOM. Cada linha representa uma questão e contém:

- `numero_exame` (texto), `data_exame` (data ISO), `tipo_prova` (inteiro, sempre 1) e `numero_questao` (inteiro).
- `materia`, `enunciado` e alternativas A a D (texto; podem ficar vazios se a fonte não tiver o campo).
- `resposta_preliminar` e `resposta_definitiva` (texto; a resposta definitiva pode ser `ANULADA`).
- `questao_extraida` (0/1), `gabarito_definitivo` (true/false) e caminhos relativos `fonte_prova`, `fonte_gabarito_preliminar` e `fonte_gabarito_definitivo`.

Valores sem fonte ou conteúdo permanecem vazios no CSV e `NULL` no SQLite/SQL. Não há colunas separadas `anulada` ou `recurso`, nem alternativa E.

Disclaimer sobre `gabarito_definitivo`: nas edições em que a banca indeferiu todos os recursos, o gabarito preliminar foi mantido e não houve publicação de um gabarito definitivo separado. Nesses casos, `gabarito_definitivo` fica `false`, e `resposta_definitiva` e `fonte_gabarito_definitivo` ficam vazias por esse motivo; a resposta preliminar continua registrada em `resposta_preliminar`. Esse vazio não significa falha na coleta de um arquivo existente.

Tratamento aplicado aos casos especiais

- Quando documento ou comunicado oficial confirma anulação, `resposta_definitiva` recebe `ANULADA`.
- Quando existe gabarito definitivo publicado, ele fornece a resposta final. Quando comunicado oficial confirma que o preliminar foi mantido integralmente, o preliminar também é usado como definitivo.
- A view `questoes_llm` exclui questões anuladas, incompletas ou sem resposta definitiva. Os demais registros permanecem na tabela principal.

Entregas da extração

O ambiente foi preparado com `uv`. A coleta completa desde o exame mais antigo do acervo foi executada com `uv run extensao tudo --exame-inicial 2010.2`; para reprocessar os PDFs já baixados, foi usado `uv run extensao extrair`. Os arquivos foram gravados em `dados/`:

- `questoes_oab.sqlite`: banco autocontido; `questoes_oab.sql`: schema, registros e view; `questoes_oab.csv`: dados tabulares.

A view `questoes_llm` contém 1.819 questões. Dez registros estão marcados com `questao_extraida=false` e são excluídos automaticamente da view.